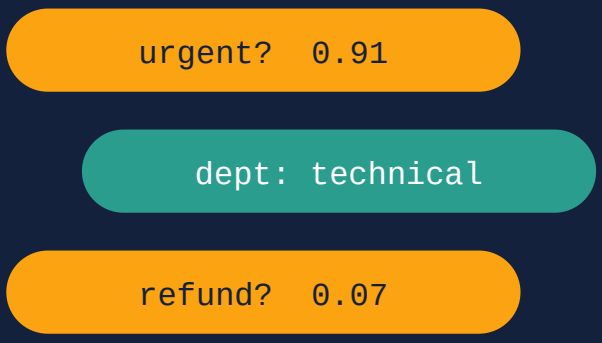


MATERI SPEAKER

Naskah Pembicara

JEV AI · 20 menit presentasi + 10 menit tanya jawab
Run sheet, naskah per slide, dan bank Q&A

Disusun 21 Oktober 2026 · Fakta harga & versi dapat berubah, cek docs.typesafe.ai

Gambaran sesi

Item	Detail
Durasi	20 menit materi + 10 menit tanya jawab
Materi pendukung	JEV_AI_Presentasi.pptx (15 slide, speaker notes sudah di dalam) dan JEV_AI_Panduan.pdf sebagai bahan bagikan
Asumsi audiens	Campuran tim produk, engineer, dan manajer yang sudah mengenal ChatGPT/Claude. Untuk audiens murni teknis, perpanjang slide 6; untuk audiens bisnis, perpanjang slide 8 dan 10
Tujuan	Audiens paham apa itu Jev, kapan memakainya vs LLM, dan pulang dengan satu ide pilot di organisasinya
Pesan utama	**Jev memutuskan, LLM menulis.**
Panjang naskah	±1.500 kata, sekitar 13–14 menit bila dibaca. Sisa ±6 menit untuk jeda, interaksi angkat tangan di slide 1, dan demo singkat di slide 6

Run sheet

Waktu	Slide	Pesan kunci
00:00 – 01:00	1. JEV AI — Ketika AI berhenti menulis dan mulai memutuskan	Mari mulai dari masalahnya.
01:00 – 02:30	2. Masalahnya: AI kita terlalu banyak bicara	Jadi, sebenarnya Jev itu apa?
02:30 – 04:00	3. Apa itu Jev?	Sekarang, bagaimana cara kerjanya?
04:00 – 05:30	4. Cara kerjanya: state + pertanyaan	Pertanyaannya sendiri hanya ada tiga jenis.
05:30 – 07:30	5. Tiga primitive: Choice, Score, Noul	Kita lihat contoh nyatanya.
07:30 – 09:00	6. Contoh: satu tiket, tiga pertanyaan, satu panggilan	Lalu bagaimana kita tahu kapan bisa percaya jawabannya?
09:00 – 10:30	7. Confidence: tahu kapan tidak yakin	Sekarang soal yang paling sering ditanyakan: biaya.
10:30 – 12:00	8. Kenapa murah dan cepat	Murah dan cepat, tapi seberapa akurat?
12:00 – 13:30	9. Akurasi: setara kelas menengah, bukan juara	Jadi, di mana tepatnya Jev cocok dipakai?
13:30 – 15:00	10. Di mana Jev cocok	Bagaimana Jev ditempatkan dalam arsitektur?
15:00 – 16:15	11. Arsitektur: Sistem 1 + Sistem 2	Tentu, Jev juga punya keterbatasan.
16:15 – 17:30	12. Batasan yang wajib diketahui	Kalau mau mencoba, bagaimana cara mengaksesnya? Lewat API.

Waktu	Slide	Pesan kunci
17:30 – 18:45	13. Akses lewat API: pilih jalurnya	Setelah tahu jalurnya, ini urutan langkah mulainya.
18:45 – 19:20	14. Mulai dalam 4 langkah	Mari saya rangkum.
19:20 – 20:00	15. Ringkasan & tanya jawab	Buka tanya jawab
20:00 – 30:00	Tanya jawab	Lihat bank pertanyaan di bagian akhir

Kolom “Pesan kunci” berisi kalimat transisi ke slide berikutnya. Jika waktu mepet, padatkan slide 3, 9, dan 13 menjadi masing-masing 45 detik; jangan memotong slide 7 (confidence) dan 11 (arsitektur) karena keduanya pembawa pesan utama.

Persiapan sebelum tampil

- ☐ Buka PPT dalam Presenter View agar speaker notes terlihat.
- ☐ Buka halaman demo “Demo Triase Jev” di tab browser terpisah; pilih tiket T-102 sebagai titik awal.
- ☐ Buat API key SumoPod khusus demo (menu AI → API Keys): beri batas kredit, mis. US$1, dan batasi model ke jev-1.13.0 + satu LLM. Key berawalan sk- dan hanya tampil sekali.
- ☐ Jika punya API key: uji `python demo_jev_triase.py` sehari sebelumnya. Tanpa key/internet: pakai `--simulasi`.
- ☐ Cek ulang harga & versi terbaru di docs.typesafe.ai pada hari-H (materi disusun 21 Oktober 2026).
- ☐ Siapkan satu contoh kasus dari organisasi audiens untuk disebut di slide 10.
- ☐ Latihan sekali dengan timer; target selesai di menit 19:30 untuk cadangan.

Skenario demo (di slide 6, ±90 detik)

Demo memakai kasus triase tiket customer service e-commerce berbahasa Indonesia. Satu panggilan per tiket, empat pertanyaan: departemen (Choice), mendesak (Noul), minta refund (Noul), dan tingkat frustrasi (Score). Angka di halaman demo dan mode `--simulasi` bersifat ilustratif; sebutkan ini ke audiens.

Detik	Lakukan	Ucapkan
0–15	Klik tiket **T-102** (ditagih dua kali, huruf kapital)	“Ini request-nya: satu state, empat pertanyaan, satu panggilan.”
15–35	Tunjuk panel Jawaban Jev	“Bukan paragraf, tapi angka: pembayaran 0,80, mendesak 0,97, frustrasi hampir maksimal.”
35–50	Tunjuk panel Keputusan: baris kode yang menyala	“Yang memutuskan eskalasi P1 adalah kode kita, bukan prompt.”
50–70	Klik **T-105** (“warnanya beda sama yg di foto”)	“Confidence 0,44: Jev bilang dirinya ragu, jadi tiket ini otomatis ke manusia.”
70–90	Geser slider **Batas ragu** ke 0,40, lihat T-105 berubah; lalu klik **Kembalikan ambang awal**	“Kebijakan berubah? Geser angka. Prompt tidak disentuh sama sekali.”

Versi visual dengan Python (disarankan untuk layar): `pip install -r requirements.txt` lalu `streamlit run demo_jev_app.py`. Browser membuka aplikasi dengan grafik probabilitas, gauge ambang, peta keputusan semua tiket, slider kebijakan, tab pembanding LLM, dan kolom **"Coba pesan dari audiens"** untuk mengetik pesan langsung dari ruangan (mode live). Pilih sumber di sidebar: Simulasi, Jev via SumoPod, atau Jev via TypeSafe. Langkah demo di tabel tetap sama; tab "Peta semua tiket" paling kuat untuk momen geser slider.

Jika ingin live dengan API: jalankan `python demo_jev_triase.py` di terminal (butuh `pip install typesafe-sdk` dan TYPESAFE_API_KEY). Hasil asli bisa berbeda dari angka simulasi; itu justru poin bagus untuk dibahas, terutama untuk teks Bahasa Indonesia informal seperti T-105. Dengan SUMOPOD_API_KEY: jalankan `--jev-sumopod` untuk memanggil jev-1.13.0 lewat SumoPod (cek dulu dengan `--cek-sumopod`), tambahkan `--draf-sumopod` agar LLM via SumoPod menulis draf balasan setelah Jev memutuskan, atau jalankan `--pembanding-sumopod` untuk mengerjakan tugas yang sama dengan LLM biasa sebagai perbandingan.

Naskah per slide

Slide 1 · JEV AI — Ketika AI berhenti menulis dan mulai memutuskan

Waktu: 00:00 – 01:00

Selamat pagi/siang semuanya. Coba angkat tangan: siapa yang di tim atau kantornya sudah memakai ChatGPT, Claude, atau Gemini di dalam aplikasi? Hampir semua, ya. Sekarang pertanyaan kedua: dari semua panggilan AI itu, berapa banyak yang sebenarnya hanya butuh jawaban 'ya' atau 'tidak'? Itulah topik kita hari ini. Saya akan membahas JEV AI, model dari TypeSafe AI yang dirilis bulan lalu, tepatnya 15 September 2026. Yang membuatnya menarik: Jev sama sekali tidak menulis teks. Ia hanya memutuskan. Dalam 20 menit ke depan kita akan bahas apa itu Jev, cara kerjanya, kapan cocok dan kapan tidak, lalu 10 menit terakhir untuk tanya jawab.

Transisi: Mari mulai dari masalahnya.

Slide 2 · Masalahnya: AI kita terlalu banyak bicara

Waktu: 01:00 – 02:30

Bayangkan sebuah AI agent yang setiap hari memproses ribuan email masuk. Untuk tiap email, ia bertanya: 'Apakah email ini mendesak?' Kalau kita tanya ke LLM biasa, jawabannya seperti di kiri: satu paragraf penjelasan. Padahal kode kita hanya butuh satu hal: ya atau tidak. Masalahnya ada tiga. Pertama, biaya: LLM menagih per token output, dan setiap kata penjelasan itu dibayar. Kedua, kecepatan: menulis kata demi kata itu lambat. Ketiga, keandalan: kode kita harus mem-parsing teks bebas, dan sesekali formatnya meleset. Jev mengambil jalan lain: jawabannya langsung 'ya, 0,91'. Angka 0,91 itu probabilitas, bukan basa-basi. Kode bisa langsung memakainya untuk if-else.

Transisi: Jadi, sebenarnya Jev itu apa?

Slide 3 · Apa itu Jev?

Waktu: 02:30 – 04:00

Jev adalah model keputusan dari TypeSafe AI, startup di San Francisco. Salah satu pendirinya, Diogo Almeida, sebelumnya di OpenAI dan terlibat dalam riset RLHF dan InstructGPT. Mereka keluar dari mode stealth dengan pendanaan seed 40 juta dolar yang dipimpin DCVC. TypeSafe menyebut Jev sebagai 'System One model'. Istilah ini dipinjam dari buku Daniel Kahneman, Thinking, Fast and Slow: Sistem 1 adalah cara berpikir cepat dan intuitif, Sistem 2 lambat dan deliberatif. LLM seperti GPT atau Claude itu Sistem 2: menalar dan menulis. Jev itu Sistem 1: penilaian kilat. Nama Jev juga merujuk ke Paradoks Jevons: kalau sebuah keputusan jadi sangat murah, kita tidak menghematnya lagi, kita justru memakainya ribuan kali di seluruh sistem. Versi stabil saat ini jev-1.13, dan jev-1.14 tersedia sebagai preview sejak 14 Oktober.

Transisi: Sekarang, bagaimana cara kerjanya?

Slide 4 · Cara kerjanya: state + pertanyaan

Waktu: 04:00 – 05:30

Polanya sederhana dan selalu sama. Anda mengirim dua hal. Pertama, state: konteksnya, bisa teks biasa atau JSON, misalnya isi tiket support plus kebijakan refund. Kedua, daftar pertanyaan bertipe yang ingin dijawab tentang state itu. Jev membaca state sekali, lalu menjawab semua pertanyaan secara paralel dalam satu forward pass. Hasilnya bukan kalimat, melainkan nilai bertipe lengkap dengan probabilitas. Lalu yang mengambil keputusan akhir adalah kode Anda sendiri. Ini poin penting: kontrol bisnis tetap di kode, bukan di prompt. Teknisnya cuma satu endpoint: POST ke api.typesafe.ai/v1/systemone. Dan karena pertanyaan dijawab paralel, menambah pertanyaan hampir tidak menambah waktu. Dokumentasinya mencontohkan 13 pertanyaan dalam satu panggilan: 11,5 kali lebih murah dan 9,6 kali lebih cepat dibanding 13 panggilan terpisah.

Transisi: Pertanyaannya sendiri hanya ada tiga jenis.

Slide 5 · Tiga primitive: Choice, Score, Noul

Waktu: 05:30 – 07:30

Ini inti dari Jev. Hanya ada tiga tipe pertanyaan. Pertama, Choice: 'yang mana?'. Pilih satu dari daftar opsi yang Anda tentukan, sampai 255 opsi. Contoh: tiket ini untuk tim billing, teknis, atau sales? Hasilnya: pilihan, probabilitas tiap opsi, dan nilai confidence. Kedua, Score: 'di level mana?'. Anda mendefinisikan 2 sampai 10 level berurutan, misalnya tingkat frustrasi pelanggan: tenang, kesal tapi sopan, sangat marah. Jev mengembalikan posisi di skala itu, bisa di antara dua level. Ketiga, Noul: 'benar atau tidak?'. Hasilnya satu angka probabilitas dari 0 sampai 1. Mendekati 1 berarti ya kuat, mendekati 0 tidak kuat, sekitar 0,5 berarti ragu. Karena jawaban selalu dibatasi pada opsi yang Anda berikan, Jev tidak mungkin mengembalikan nilai di luar skema. Tetapi perlu diingat: jawaban yang valid secara format belum tentu benar. Jev tetap bisa salah klasifikasi.

Transisi: Kita lihat contoh nyatanya.

Slide 6 · Contoh: satu tiket, tiga pertanyaan, satu panggilan

Waktu: 07:30 – 09:00

Ini request yang hampir sama dengan contoh di dokumentasi resmi. State-nya: pelanggan mengeluh integrasi API error 500 sejak 20 menit lalu dan tidak bisa memproses pesanan. Kita tanya tiga hal sekaligus: departemen mana yang menangani, dengan Choice; apakah mendesak, dengan Noul; dan seberapa frustrasi pelanggannya, dengan Score. Di kanan, jawabannya kembali sebagai nilai yang langsung bisa dipakai kode. Angka di slide ini ilustrasi, tapi bentuknya persis seperti itu. Lalu kode kita yang memutuskan: kalau teknis dan urgensi di atas 0,8, buka insiden prioritas tinggi; kalau frustrasi tinggi, kirim ke senior agent. Perhatikan: kalau besok kebijakan berubah, kita cukup mengubah angka ambang di kode, tanpa menulis ulang prompt. Sekarang saya tunjukkan versi interaktifnya dengan lima contoh tiket. (Pindah ke halaman Demo Triase Jev, ikuti skenario demo 90 detik.)

Transisi: Lalu bagaimana kita tahu kapan bisa percaya jawabannya?

Slide 7 · Confidence: tahu kapan tidak yakin

Waktu: 09:00 – 10:30

Ini fitur yang menurut saya paling penting. Setiap jawaban Choice dan Score membawa nilai confidence dari 0 sampai 1, yang dihitung dari sebaran probabilitas, bukan dari model yang 'merasa yakin'. Untuk Noul, probabilitasnya sendiri sudah menunjukkan keyakinan. TypeSafe menyarankan pola tiga jalur. Confidence tinggi: jalankan otomatis. Sedang: lanjut dengan hati-hati, misalnya minta konfirmasi pengguna. Rendah: jangan bertindak, serahkan ke manusia. Dan ambangnya harus sesuai risiko. Contoh dari dokumentasi: kalau pengguna ingin cek saldo, salah tampil layar itu bisa dipulihkan, jadi ambangnya rendah. Kalau menyetujui transfer dana, butuh confidence di atas 0,9 dan tetap dengan konfirmasi. Ambang ini bukan angka sakti; mulai konservatif, uji dengan data Anda, lalu sesuaikan.

Transisi: Sekarang soal yang paling sering ditanyakan: biaya.

Slide 8 · Kenapa murah dan cepat

Waktu: 10:30 – 12:00

Harga resmi Jev: 0,042 dolar per satu juta token input. Output gratis, karena memang tidak ada teks yang ditulis. Latensinya sekitar 70 sampai 500 milidetik per panggilan. Mari kita hitung: satu juta panggilan, masing-masing 500 token, total 500 juta token input. Dikali 0,042 dolar per juta, hasilnya sekitar 21 dolar. Sebagai pembanding, LLM umumnya dihargai 0,2 sampai 10 dolar per juta token input, dan output biasanya beberapa kali lebih mahal. TypeSafe sendiri mengklaim hingga sekitar 200 kali lebih cepat dan 400 kali lebih murah untuk tugas klasifikasi. Tapi ingat, itu klaim vendor; selalu uji di beban kerja Anda sendiri. Satu catatan harga: ini harga per Oktober 2026, cek halaman resmi sebelum membuat proyeksi.

Transisi: Murah dan cepat, tapi seberapa akurat?

Slide 9 · Akurasi: setara kelas menengah, bukan juara

Waktu: 12:00 – 13:30

Di benchmark empat workflow milik TypeSafe, Jev mendapat 67,8 persen, setara GPT-5.6 Terra di 67,9 persen, dan beberapa poin di bawah Claude Opus 5 di 73,1 dan GPT-5.6 Sol di 74,1. Jadi pesannya jujur: Jev tidak lebih pintar dari model frontier. Keunggulannya adalah akurasi yang cukup dengan biaya dan kecepatan yang jauh lebih baik. Studi independen memberi gambaran serupa. Paper evaluasi di arXiv melaporkan akurasi 95 sampai 99 persen pada benchmark klasifikasi seperti IMDB dan SST-2, dan probabilitasnya terkalibrasi baik. Tapi di ujian lisensi fisioterapi Korea yang butuh pengetahuan domain mendalam, Jev mendapat 74,2 persen, di bawah GPT-4o yang 85,8 persen. Kesimpulannya: Jev unggul untuk keputusan cepat bervolume tinggi, bukan penalaran yang dalam.

Transisi: Jadi, di mana tepatnya Jev cocok dipakai?

Slide 10 · Di mana Jev cocok

Waktu: 13:30 – 15:00

Ini enam pola yang paling sering muncul. Satu, model routing: menilai setiap prompt dan mengirimnya ke LLM termurah yang sanggup, sudah didukung LiteLLM lewat JEV Auto Router. Dua, guardrail: mendeteksi prompt injection, konten kasar, atau input di luar kebijakan sebelum sampai ke LLM. Tiga, gating tool-call untuk agent: apakah aksi ini boleh, perlu konfirmasi, atau ditolak. Empat, triase inbox dan tiket. Lima, reranking hasil pencarian RAG berdasarkan relevansi. Enam, evaluasi output LLM dan pelabelan data massal, misalnya jutaan baris. Ada juga kontrol real-time: TypeSafe mendemokan Jev memainkan game Doom dengan 10 panggilan per detik. Benang merahnya: ruang jawabannya terbatas dan keputusannya diulang ribuan kali.

Transisi: Bagaimana Jev ditempatkan dalam arsitektur?

Slide 11 · Arsitektur: Sistem 1 + Sistem 2

Waktu: 15:00 – 16:15

Jev bukan pengganti LLM; ia pasangannya. Lihat alurnya: input masuk, Jev melakukan pemeriksaan cepat di depan, apakah aman, apa maksudnya, seberapa sulit. Dari situ ada tiga jalur. Yang sederhana dijawab otomatis atau oleh model kecil. Yang butuh menulis atau menalar diteruskan ke LLM besar. Yang berisiko atau confidence-nya rendah diserahkan ke manusia. Setelah LLM menulis, Jev bisa dipakai lagi di belakang untuk menilai hasilnya: apakah jawaban relevan, apakah sesuai kebijakan. Dengan kata lain: Jev memutuskan jalannya, LLM tetap yang menulis. Kalimat ini yang ingin saya tinggalkan di kepala Anda.

Transisi: Tentu, Jev juga punya keterbatasan.

Slide 12 · Batasan yang wajib diketahui

Waktu: 16:15 – 17:30

TypeSafe cukup terbuka soal ini lewat halaman 'jaggedness'. Pertama, Jev bukan kalkulator: jangan suruh menghitung atau membandingkan tanggal; lakukan di kode, biarkan Jev menilai hal yang semantik. Kedua, Jev membaca secara literal: ia menjawab apa yang Anda tulis, bukan yang Anda maksud, jadi tulis kondisinya sejelas mungkin. Ketiga, state yang besar dan penuh hal tak relevan menurunkan akurasi, istilahnya context rot; filter dulu. Keempat, konten adversarial bisa menggeser jawaban, jadi uji kasus ekstrem. Kelima, pada Choice, opsi pertama cenderung sedikit diunggulkan; acak urutan untuk mengecek konsistensi. Dan khusus untuk kita di Indonesia: bahasa utama pelatihannya Inggris. Bahasa lain didukung, tapi tidak sebaik itu. Jadi wajib uji dengan data berbahasa Indonesia sebelum produksi.

Transisi: Kalau mau mencoba, bagaimana cara mengaksesnya? Lewat API.

Slide 13 · Akses lewat API: pilih jalurnya

Waktu: 17:30 – 18:45

Pertanyaan yang hampir selalu muncul: bisakah Jev diakses lewat API? Jawabannya ya, dan ada beberapa jalur. Jalur utama adalah REST API langsung dari TypeSafe: satu endpoint, POST ke api.typesafe.ai/v1/systemone, dengan header Authorization Bearer berisi API key dari console.typesafe.ai. Body-nya tiga field: model, state, dan questions. Karena ini HTTP biasa, bahasa apa pun bisa memanggilnya, termasuk PHP atau Go. Kedua, SDK resmi: pip install typesafe-sdk untuk Python dan npm install @typesafe-ai/sdk untuk JavaScript; keduanya membaca variabel lingkungan TYPESAFE_API_KEY. Ketiga, lewat gateway yang mungkin sudah Anda pakai: Vercel AI Gateway dengan base URL ai-gateway.vercel.sh/typesafe dan model typesafe-ai/jev, tagihannya ikut Vercel atau bawa key sendiri; Netlify AI Gateway dari Netlify Functions tanpa perlu API key terpisah; serta LiteLLM dan Zuplo sebagai proxy. Saran saya: untuk percobaan, pakai REST atau SDK langsung; untuk produksi yang sudah memakai gateway, tinggal ganti base URL.

Transisi: Setelah tahu jalurnya, ini urutan langkah mulainya.

Slide 14 · Mulai dalam 4 langkah

Waktu: 18:45 – 19:20

Ringkasnya ada empat langkah. Satu: coba dulu di Playground TypeSafe dengan kasus nyata yang risikonya rendah. Dua: buat API key di console.typesafe.ai; akses awal masih lewat waitlist. Tiga: pilih jalur API yang tadi kita bahas. Empat, yang paling sering dilupakan: buat dataset evaluasi, tentukan ambang confidence, dan kunci versi model. Alias jev-latest bisa berpindah versi, jadi untuk produksi gunakan ID seperti jev-1.13.0.

Transisi: Mari saya rangkum.

Slide 15 · Ringkasan & tanya jawab

Waktu: 19:20 – 20:00 (lalu Q&A; 20:00 – 30:00)

Tiga hal untuk dibawa pulang. Satu: Jev memutuskan, LLM menulis; pakai masing-masing untuk tugasnya. Dua: pecah keputusan besar menjadi pertanyaan-pertanyaan kecil, lalu gabungkan di kode dengan bobot yang Anda kontrol. Tiga: confidence adalah fitur; gunakan untuk memutuskan kapan otomatis dan kapan melibatkan manusia. Kategori System One model ini baru berumur sekitar lima minggu, jadi kemungkinan besar penyedia lain akan menyusul. Pola berpikirnya yang penting untuk dikuasai sekarang. Terima kasih. Saya buka 10 menit untuk tanya jawab.

Transisi: Buka sesi tanya jawab.

Tanya jawab (10 menit)

Cara memandu

- Ulangi pertanyaan dengan singkat agar seluruh ruangan mendengar.
- Jawab maksimal 60 detik; targetkan 5–7 pertanyaan dalam 10 menit.
- Jika tidak tahu: “Pertanyaan bagus, saya belum punya data pastinya. Saya cek dan kabari setelah sesi.” Catat di *parking lot*.
- Jika hening: lempar pertanyaan pemancing, misalnya “Di tim Anda, keputusan apa yang diulang ribuan kali per hari?”
- Tutup tepat waktu di menit 30 dengan mengulang pesan utama: Jev memutuskan, LLM menulis.

Bank pertanyaan & jawaban

1. Apakah Jev bisa diakses lewat API?

Ya. Jalur utamanya REST API: POST ke https://api.typesafe.ai/v1/systemone dengan header Authorization: Bearer berisi API key dari console.typesafe.ai. Ada SDK resmi Python (pip install typesafe-sdk) dan JavaScript (npm install @typesafe-ai/sdk), serta jalur via Vercel AI Gateway, Netlify AI Gateway, LiteLLM, dan Zuplo. Karena HTTP biasa, bahasa apa pun bisa memanggilnya.

2. Bisa pakai SumoPod?

Bisa. SumoPod menyediakan jev-1.13.0 di endpoint /v1/systemone dengan format request TypeSafe, dan saldonya bisa dipakai untuk Jev maupun LLM lain. Di demo: python demo_jev_triase.py --jev-sumopod, atau pilih mode “Jev via SumoPod” di aplikasi visual. Catatan: latensi via gateway bisa lebih tinggi (di playground ±1,6 detik untuk satu request), dan tarif mengikuti SumoPod.

3. Apa bedanya dengan LLM yang dipaksa output JSON (structured output)?

LLM dengan structured output tetap menulis token satu per satu, output tetap dibayar, dan kadang formatnya gagal. Jev mengembalikan distribusi probabilitas atas opsi Anda dalam satu forward pass, output gratis, dan jawabannya tidak bisa keluar dari skema. Bonusnya: probabilitas yang terkalibrasi, bukan sekadar label.

4. Apakah Jev bisa berhalusinasi?

Jev tidak bisa mengembalikan nilai di luar opsi yang Anda definisikan. Tapi ia tetap bisa memilih opsi yang salah. Karena itu gunakan confidence untuk eskalasi dan uji dengan dataset evaluasi.

5. Apakah Jev mendukung Bahasa Indonesia?

Ya, teks berbahasa lain diterima, tetapi dokumentasi menyebut bahasa Inggris sebagai bahasa pelatihan utama dengan akurasi terbaik. Wajib uji pada data Bahasa Indonesia Anda dan perhatikan confidence. Salah satu opsi yang layak diuji: instruksi dan criteria dalam bahasa Inggris, state tetap dalam Bahasa Indonesia.

6. Apakah data kami dipakai untuk melatih model?

Menurut dokumentasi TypeSafe, tidak. Ada Data Processing Agreement, dan zero data retention tersedia untuk pelanggan enterprise. Untuk data sensitif, tetap lakukan review legal.

7. Bisa di-fine-tune dengan data kami?

Tidak. Semua akun memakai bobot yang sama. Kustomisasi dilakukan lewat state, instruksi, criteria, dan logika di kode. Jika butuh model hilir, probabilitas Jev bisa dijadikan fitur untuk model klasik.

8. Berapa biaya riilnya?

Rumusnya: total token input ÷ 1 juta × US$0,042. Contoh: 100 ribu tiket per hari × 1.000 token = 100 juta token ≈ US$4,20 per hari. Output gratis.

9. Berapa panjang konteks maksimum?

64k token per request dan 32k per pertanyaan. Ada mode long context hingga 262k dengan header khusus, tapi lebih lambat dan kurang akurat. Praktik terbaiknya justru memfilter state agar ringkas.

10. Kapan sebaiknya TIDAK memakai Jev?

Untuk menulis atau merangkum, matematika dan perbandingan tanggal, penalaran multi-langkah, dan keputusan berisiko tinggi tanpa review manusia.

11. Aman untuk keputusan kritis seperti kredit atau medis?

Belum disarankan sebagai pengambil keputusan tunggal. Studi ujian fisioterapi menunjukkan Jev masih di bawah GPT-4o untuk pengetahuan domain mendalam. Mulai dari kasus berisiko rendah, gunakan human-in-the-loop, dan konfirmasi status kepatuhan ke TypeSafe.

12. Bagaimana integrasi dengan stack yang sudah ada?

Kalau sudah memakai gateway, biasanya cukup ganti base URL: Vercel AI Gateway (ai-gateway.vercel.sh/typesafe), Netlify AI Gateway, LiteLLM (termasuk JEV Auto Router), atau Zuplo. Selain itu ada contoh harness dari LangChain, dan server MCP buatan komunitas untuk agent seperti Claude Code.

13. Bagaimana menentukan ambang confidence?

Gunakan dataset berlabel, lihat akurasi pada berbagai ambang (berapa persen kasus bisa otomatis dengan akurasi target). Bedakan ambang per jenis aksi sesuai risikonya. Mulai konservatif, lalu longgarkan berdasarkan data.

14. Apakah hasil bisa berubah tanpa kami mengubah kode?

Bisa, jika memakai alias jev-latest yang berpindah saat versi baru rilis. Untuk produksi, kunci ID versi seperti jev-1.13.0 dan log field model di setiap respons.

15. Apakah ada alternatif atau versi open-source?

Belum ada padanan resmi, tetapi mekanisme serupa bisa didekati dengan endpoint scoring seperti /v1/score di SGLang pada model terbuka. Kemungkinan besar penyedia lain akan merilis model sejenis; pola pikirnya tetap berlaku.

16. Seberapa cepat? Bisa real-time?

Sekitar 70–500 ms per panggilan. TypeSafe mendemokan Jev memainkan Doom dengan 10 panggilan per detik, jadi cocok untuk loop kontrol yang butuh keputusan tiap beberapa ratus milidetik.

17. Bagaimana dengan rate limit?

Ditetapkan per organisasi dalam token per detik dan request per detik. Jika terlampaui, API mengembalikan 429 dan SDK otomatis mencoba ulang. Limit lebih tinggi tersedia di paket custom/enterprise.

Kalimat penutup sesi

> “Terima kasih atas pertanyaannya. Kalau hanya satu hal yang diingat: **Jev memutuskan, LLM menulis.** Coba cari satu keputusan di tim Anda yang diulang ribuan kali per hari; itu kandidat pilot terbaik. Panduan lengkapnya ada di PDF yang saya bagikan. Selamat mencoba!”