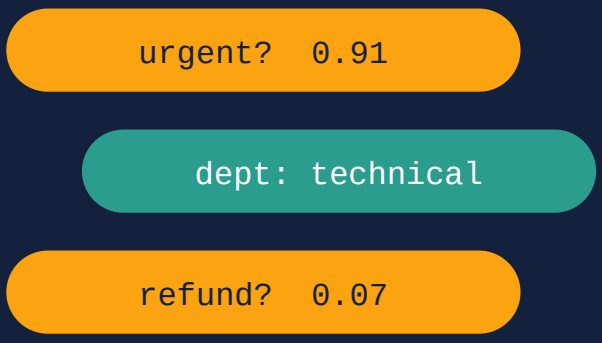


PANDUAN PRAKTIS

Panduan JEV AI

Model keputusan System One dari TypeSafe AI:
apa itu, cara kerja, kapan dipakai, dan batasannya

Disusun 21 Oktober 2026 · Fakta harga & versi dapat berubah, cek docs.typesafe.ai

Ringkasan dalam satu halaman

Jev adalah model AI dari **TypeSafe AI** (rilis 15 September 2026) yang **tidak menulis teks**. Anda memberi konteks (*state*) dan pertanyaan bertipe; Jev mengembalikan jawaban terstruktur beserta probabilitas yang bisa langsung dipakai kode untuk mengambil keputusan.

Aspek	Ringkasnya
Kategori	“System One model”: penilaian cepat ala Sistem 1 (Kahneman), bukan penalaran panjang ala Sistem 2
Tipe pertanyaan	**Choice** (pilih satu opsi), **Score** (posisi pada skala berlevel), **Noul** (probabilitas ya/tidak)
Akses API	REST `POST https://api.typesafe.ai/v1/systemone`, SDK Python & JS, atau via Vercel / Netlify AI Gateway, LiteLLM, Zuplo
Harga	US$0,042 per juta token input; output gratis
Kecepatan	Sekitar 70–500 ms per panggilan; banyak pertanyaan dijawab paralel dalam satu panggilan
Akurasi	Setara model kelas menengah (67,8% di benchmark 4 workflow TypeSafe), di bawah model frontier
Paling cocok	Routing, guardrail, triase, reranking, evaluasi, pelabelan massal: keputusan berulang dengan jawaban terbatas
Tidak cocok	Menulis/merangkum, matematika, perbandingan tanggal, penalaran multi-langkah
Bahasa	Inggris paling akurat; Bahasa Indonesia didukung tetapi wajib diuji

1. Apa itu Jev?

Kebanyakan panggilan AI di dalam aplikasi sebenarnya bukan permintaan untuk menulis, melainkan penilaian kecil: apakah pesan ini mendesak, tim mana yang harus menangani, apakah aksi agent ini aman. Jika LLM generatif dipakai untuk itu, kita membayar dan menunggu setiap kata penjelasan, lalu masih harus mem-parsing teksnya.

TypeSafe AI, startup asal San Francisco yang didirikan antara lain oleh mantan peneliti OpenAI Diogo Almeida, merilis Jev sebagai jawaban atas masalah itu. Perusahaan ini keluar dari mode stealth dengan pendanaan seed US$40 juta yang dipimpin DCVC. Mereka menamai kategori ini **System One model**, meminjam istilah Daniel Kahneman: Sistem 1 berpikir cepat dan intuitif, Sistem 2 lambat dan deliberatif. Nama Jev sendiri merujuk ke Paradoks Jevons: ketika keputusan menjadi sangat murah, orang tidak menghematnya lagi, tetapi memakainya di ribuan titik.

	LLM generatif (Sistem 2)	Jev (Sistem 1)
Keluaran	Teks bebas (opsional dipaksa ke JSON)	Hanya nilai bertipe: pilihan, skor, atau probabilitas
Biaya output	Dibayar per token, umumnya lebih mahal dari input	Gratis

	LLM generatif (Sistem 2)	Jev (Sistem 1)
Cara menjawab	Menulis token satu per satu	Satu forward pass, semua pertanyaan paralel
Keyakinan	Harus ditanyakan/ditebak dari teks	Probabilitas & confidence terkalibrasi bawaan
Kekuatan	Menulis, menalar, merangkum, kode	Klasifikasi & penilaian cepat bervolume tinggi

2. Cara kerja

Setiap panggilan selalu berpola sama. Anda mengirim **state** (teks, objek JSON, atau array teks) dan sekumpulan **pertanyaan** dengan ID pilihan Anda. Jev membaca state sekali, menilai semua pertanyaan secara independen dan paralel, lalu mengembalikan jawaban di bawah ID yang sama. Keputusan akhir dibuat oleh kode Anda.

- **Tanpa batas jumlah pertanyaan**, selama request muat dalam batas konteks: 64k token per request dan 32k token per pertanyaan.
- **Tanyakan sekaligus.** Dokumentasi resmi mencontohkan 13 pertanyaan dalam satu panggilan: 11,5× lebih murah dan 9,6× lebih cepat daripada 13 panggilan terpisah (pola *speculative fan-out*).
- **Jawaban independen.** Jawaban satu pertanyaan tidak menjadi konteks pertanyaan lain. Jika memang ada ketergantungan, buat panggilan kedua dari kode.
- **Tunjuk bagian state dengan path**, misalnya `` `ticket.messages[0].text` ``, agar model tahu bagian mana yang dinilai.

3. Tiga primitive

Tipe	Menjawab	Bentuk criteria	Mengembalikan	Contoh
Choice	Yang mana?	Peta opsi (hingga 255) + deskripsi	choice, probabilities, confidence	Tiket ke billing / teknis / sales
Score	Di level mana?	Daftar level berurutan (2–10)	score, legend, probabilities, confidence	Frustrasi: tenang → sangat marah
Noul	Benar atau tidak?	Opsional: definisi ya/tidak	noul (0–1)	Apakah pelanggan minta refund?

Cara memilih tipe

- **Choice** bila jawabannya satu dari daftar tanpa urutan. Tambahkan opsi *other* atau *none of the above* jika daftar mungkin tidak lengkap.
- **Score** bila jawabannya berada di spektrum yang bisa Anda definisikan per level (keparahan bug, tingkat keahlian).
- **Noul** untuk ya/tidak yang bersih. Ingat: Noul 0,5 berarti model ragu, bukan “sedang”. Untuk mengukur tingkat, pakai Score.
- Jika dua tipe sama-sama cocok, pilih yang hasilnya paling langsung bisa dipakai kode: Choice → beberapa cabang, Score → ambang, Noul → `if`.

4. Contoh kode (Python)

Contoh berikut mengikuti pola di dokumentasi resmi TypeSafe: satu state, tiga pertanyaan berbeda tipe, satu panggilan.

```
from typesafe_sdk import Choice, Noul, Score, TypeSafeClient

state = {
    "ticket_message": "Penerbangan saya dibatalkan. Bisa minta refund?",
    "refund_policy": "Penerbangan yang dibatalkan berhak refund penuh.",
}

with TypeSafeClient() as client:            # membaca TYPESAFE_API_KEY
    r = client.system_one(
        state=state,
        questions={
            "refund_requested": Noul(
                instructions="Does `ticket_message` request a refund?"),
            "request_type": Choice(
                instructions="What is the main request in `ticket_message`?",
                criteria={
                    "refund": "The customer wants money returned.",
                    "rebooking": "The customer wants a replacement flight.",
                    "information": "The customer only asks for information.",
                }),
            "frustration": Score(
                instructions="How frustrated does the customer appear?",
                criteria=["Calm and neutral.", "Concerned but civil.",
                          "Very angry or using strong language."]),
        },
    )

a = r.answers
if a["request_type"].choice == "refund" and a["refund_requested"].noul > 0.8:
    proses_refund()                          # logika bisnis tetap di kode
elif a["request_type"].confidence < 0.5:
    kirim_ke_agen_manusia()
```

Pilihan jalur akses lainnya (REST langsung, SDK JavaScript, dan gateway) ada di bagian berikutnya. Instruksi pada contoh ditulis dalam bahasa Inggris karena itulah bahasa terkuat model; uji juga versi Bahasa Indonesia pada data Anda.

5. Akses lewat API

Ya, Jev diakses sepenuhnya lewat API. Semua jalur di bawah ini memanggil endpoint yang sama di belakangnya; pilih yang paling cocok dengan stack Anda.

Jalur	Cara pakai	Kredensial & tagihan	Cocok untuk
REST API TypeSafe	`POST https://api.typesafe.ai/v1/systemone`; daftar model: `GET /v1/models`	Header `Authorization: Bearer` + key dari console.typesafe.ai; ditagih TypeSafe	Bahasa apa pun (PHP, Go, Java, dsb.)
SDK Python	`pip install typesafe-sdk`	Membaca `TYPESAFE_API_KEY`; retry 429 otomatis	Backend & data pipeline Python

Jalur	Cara pakai	Kredensial & tagihan	Cocok untuk
SDK JavaScript/TS	`npm install @typesafe-ai/sdk` (Node.js 22+)	Membaca `TYPESAFE_API_KEY`	Node, Next.js, edge function
Vercel AI Gateway	Base URL `https://ai-gateway.vercel.sh/typesafe`, model `typesafe-ai/jev`; juga lewat Decision API & AI SDK	AI Gateway API key atau OIDC; ditagih Vercel, atau BYOK key TypeSafe	Tim yang sudah di Vercel; butuh fallback ke model lain saat confidence rendah
Netlify AI Gateway	Pakai `@typesafe-ai/sdk` dari Netlify Functions	Tanpa key terpisah; ditagih ke kredit Netlify	Situs & fungsi di Netlify
LiteLLM proxy	Ganti `https://api.typesafe.ai` dengan `<LITELLM_PROXY>/typesafe`; ada JEV Auto Router	Virtual key LiteLLM; key TypeSafe disimpan di proxy	Organisasi dengan gateway LLM terpusat
Zuplo AI Gateway	Provider “Jev”, model `jev/jev-latest` atau `jev/jev-1.13.0`	Key aplikasi Zuplo; key TypeSafe di portal	Kontrol akses & filter model per aplikasi

Contoh REST (cURL)

```
curl -X POST https://api.typesafe.ai/v1/systemone \
  -H "Authorization: Bearer $TYPESAFE_API_KEY" \
  -H "Content-Type: application/json" \
  -d '{
    "model": "jev-1.13.0",
    "state": "Saya ditagih dua kali untuk langganan bulan ini.",
    "questions": {
      "billing": { "type": "noul",
                   "instructions": "Is this message about billing?" }
    }
  }'
```

Respons berisi `model` (ID versi yang menjawab), `answers` (dikunci dengan nama pertanyaan Anda), dan `usage` (hanya `input_tokens` yang ditagih; `output_tokens` saat ini gratis). Request yang tidak valid mengembalikan **422** dengan path field yang salah; melewati rate limit mengembalikan **429**. Streaming tidak tersedia.

```
{
  "model": "jev-1.13.0",
  "answers": { "billing": { "type": "noul", "noul": 0.98 } },
  "usage": { "input_tokens": 275, "output_tokens": 20 }
}
```

Nilai pada contoh respons bersifat ilustratif. Akses awal ke console.typesafe.ai masih melalui waitlist di typesafe.ai; daftar lebih awal bila ingin demo live. OpenRouter juga mencantumkan Jev Router (`typesafe/jev-router`), router model berbasis Jev; untuk memanggil Jev sendiri, gunakan jalur di tabel.

Jev lewat SumoPod

SumoPod (`https://ai.sumopod.com/v1`), gateway AI lokal yang ditagih lewat saldo SumoPod, **menyediakan Jev**: model `jev-1.13.0` di endpoint `POST /v1/systemone` dengan format request TypeSafe (state + questions), bukan `/chat/completions`. Di Decision playground SumoPod, satu request contoh (3 pertanyaan) dijawab dalam ±1,6 detik dengan 391 token input dan 67 token output, oleh versi `typesafe/jev-1.13-20260917`. Latensi lewat gateway bisa lebih tinggi daripada angka TypeSafe (70–500 ms), dan tarif serta perlakuan token output mengikuti SumoPod; cek di dashboard. Satu key SumoPod cukup untuk Jev *dan* LLM penulis draf: skrip demo menyediakan `--jev-sumopod` dan `--draf-sumopod`, aplikasi visual menyediakan mode "Jev via SumoPod".

6. Confidence dan ambang keputusan

Setiap jawaban Choice dan Score membawa nilai **confidence** 0–1 yang dihitung dari sebaran probabilitas: 1 bila semua probabilitas di satu opsi, 0 bila merata. Noul tidak memiliki confidence terpisah karena probabilitasnya sendiri sudah menunjukkan keyakinan; nilai di sekitar 0,5 berarti ragu.

Rentang	Perilaku sistem	Contoh
Tinggi	Jalankan otomatis	Tampilkan saldo, beri label tiket
Sedang	Lanjut hati-hati: minta konfirmasi, tandai untuk review, atau kumpulkan info tambahan	Kirim draf balasan ke agen untuk disetujui
Rendah (mis. < 0,5)	Jangan bertindak: serahkan ke manusia, minta klarifikasi, atau pakai sistem lain	Eskalasi ke supervisor

Ambang harus mengikuti risiko aksi. Dalam contoh dokumentasi, menampilkan saldo boleh dengan ambang rendah karena salah layar mudah dipulihkan, sedangkan menyetujui transfer dana memerlukan confidence di atas 0,9 dan tetap dengan konfirmasi pengguna. Mulailah konservatif, uji dengan data sendiri, lalu sesuaikan.

7. Harga, kecepatan, dan batas teknis

Item	Nilai (per Oktober 2026)
Model stabil	`jev-1.13.0` (alias `jev-latest`)
Model preview	`jev-1.14.0` (alias `jev-preview`), tersedia sejak 14 Oktober 2026
Harga	US$0,042 per juta token input (US$42 per miliar); token output gratis
Latensi	Sekitar 70–500 ms per panggilan (angka dari TypeSafe)
Konteks	64k token per request, 32k per pertanyaan; header `TypeSafe-Danger-Zone-Long-Context: true` menaikkan keduanya ke 262k (lebih lambat & kurang akurat)
Input	Teks saja (string, JSON, atau array teks). Audio/video harus diubah ke teks dulu
Rate limit	Per organisasi, dalam token/detik dan request/detik; kelebihan → HTTP 429, SDK otomatis retry

Item	Nilai (per Oktober 2026)
Streaming	Tidak tersedia (memang tidak ada teks yang dialirkan)

Contoh hitungan biaya

Skenario	Total token input	Perkiraan biaya
1 juta panggilan × 500 token	500 juta	≈ US$21
100.000 tiket/hari × 1.000 token	100 juta per hari	≈ US$4,20 per hari
10 juta baris data × 300 token (pelabelan sekali jalan)	3 miliar	≈ US$126

Rumus: total token input ÷ 1.000.000 × 0,042. Klaim TypeSafe: hingga ~200× lebih cepat dan ~400× lebih murah dibanding LLM sebanding untuk tugas klasifikasi. Selalu ukur pada beban kerja Anda sendiri.

8. Seberapa akurat?

Sumber	Temuan
Benchmark 4 workflow TypeSafe	Jev 67,8%, setara GPT-5.6 Terra (67,9%); di bawah Claude Opus 5 (73,1%) dan GPT-5.6 Sol (74,1%), dengan biaya sekitar 1/200
Evaluasi independen di arXiv (37 dataset)	95–99% pada IMDB, SST-2, HellaSwag, ARC; 86,7% pada Belebele (122 bahasa); probabilitas pilihan terkalibrasi baik dan mendukung *selective prediction*
Ujian lisensi fisioterapi Korea (medRxiv)	Jev 74,2% vs GPT-4o 85,8%; semua jawaban Jev valid secara format, GPT-4o 3 jawaban tidak valid
Studi kalibrasi Sys1Cal-v1 (arXiv)	Noul dan Score terkalibrasi baik; Choice cenderung terlalu yakin (miskalibrasi sistematis)

Kesimpulan praktis: Jev tidak lebih pintar daripada model frontier. Nilainya ada pada akurasi yang cukup untuk keputusan berulang dengan biaya dan latensi yang jauh lebih rendah, plus probabilitas yang bisa dipakai untuk memutuskan kapan melibatkan manusia.

9. Kasus penggunaan

Kasus	Primitive	Contoh pertanyaan
Model routing	Choice	Model termurah mana yang sanggup menyelesaikan prompt ini? (didukung JEV Auto Router di LiteLLM)
Guardrail input	Noul	Apakah pesan berisi upaya prompt injection? Berisi data pribadi?
Gating tool-call agent	Choice + Noul	Izinkan / minta konfirmasi / tolak? Apakah aksi ini tidak bisa dibatalkan?
Triase tiket & inbox	Choice + Score + Noul	Departemen? Tingkat frustrasi? Mendesak?

Kasus	Primitive	Contoh pertanyaan
Reranking RAG	Noul / Score	Apakah passage ini menjawab pertanyaan pengguna?
Evaluasi output LLM	Score + Noul	Seberapa relevan jawaban? Apakah sesuai kebijakan?
Pelabelan data massal	Choice	Kategori produk untuk jutaan baris katalog
Kontrol real-time	Choice + Score	Keputusan tiap beberapa ratus ms untuk game, bot, robot (TypeSafe mendemokan Doom pada 10 panggilan/detik)
Gerbang confidence	Semua	Otomatis, konfirmasi, atau ke manusia berdasarkan probabilitas

10. Arsitektur referensi

Tempatkan Jev sebagai pasangan LLM, bukan penggantinya:

- **Di depan:** Jev memeriksa input (aman? apa maksudnya? seberapa sulit?).
- **Percabangan:** kasus sederhana dijawab otomatis atau oleh model kecil; kasus yang perlu menulis/menalar diteruskan ke LLM besar; kasus berisiko atau ber-confidence rendah ke manusia.
- **Di belakang:** Jev menilai hasil LLM (relevan? sesuai kebijakan?) sebelum dikirim ke pengguna.

Prinsip: Jev memutuskan jalurnya; LLM tetap yang menulis. Logika bisnis dan bobot keputusan tinggal di kode, sehingga perubahan kebijakan cukup dengan mengubah angka, bukan menulis ulang prompt.

11. Batasan dan mitigasi (jev-1.13)

TypeSafe mendokumentasikan sendiri “jaggedness” model. Ringkasannya:

Kelemahan	Mitigasi
Membaca literal: menjawab yang ditulis, bukan yang dimaksud	Tulis kondisi persis; letakkan kasus batas di criteria; pecah interpretasi menjadi dua pertanyaan literal
Matematika & menghitung	Hitung di kode; untuk menghitung item, tanyakan satu Noul per item lalu jumlahkan
Perbandingan tanggal & waktu	Ekstrak komponen tanggal (Choice), lalu bandingkan di kode
Indireksi & negasi ganda	Tulis instruksi selangsung mungkin; sebut bagian state dengan nama
State besar penuh hal tak relevan (context rot)	Filter/retrieve dulu; kirim hanya field yang dibutuhkan
Konten adversarial (injection, framing menyesatkan)	Criteria eksplisit; uji kasus ekstrem sebelum rilis
Instruksi dan criteria saling bertentangan	Selaraskan bahasa; jangan memetakan true ke “no”
Urutan opsi Choice memengaruhi jawaban	Acak urutan opsi dan cek konsistensi
Generasi teks	Gunakan model generatif; jadikan ekstraksi sebagai Choice atas kandidat

Kelemahan	Mitigasi
Bahasa selain Inggris	Uji pada data Bahasa Indonesia; perhatikan confidence saat routing

12. Menulis pertanyaan yang baik

Lakukan	Hindari
Satu penilaian kilat per pertanyaan: “Apakah pesan ini menunjukkan urgensi?”	Pertanyaan besar: “Analisis pesan ini dan tentukan langkah terbaik”
Pecah penilaian kompleks jadi beberapa pertanyaan, gabungkan dengan bobot di kode (*composite scoring*)	Menyembunyikan beberapa penilaian dalam satu pertanyaan
Tulis pertanyaan lengkap di *instructions* (ID pertanyaan tidak dikirim ke model)	Mengandalkan nama ID yang “sudah jelas”
Tanyakan juga pertanyaan spekulatif yang mungkin dibutuhkan (*fan-out*)	Satu panggilan per pertanyaan
Definisikan level Score dengan deskripsi konkret	Level samar atau multi-dimensi

13. Checklist adopsi

- ☐ Inventarisasi panggilan LLM yang sebenarnya hanya butuh pilihan/skor/ya-tidak.
- ☐ Pilih satu kasus berisiko rendah dan bervolume tinggi sebagai pilot.
- ☐ Coba di TypeSafe Playground dengan contoh nyata.
- ☐ Buat API key di console.typesafe.ai (akses awal melalui waitlist).
- ☐ Siapkan dataset evaluasi berlabel, termasuk kasus ekstrem dan data Bahasa Indonesia.
- ☐ Bandingkan akurasi, latensi, dan biaya dengan solusi saat ini.
- ☐ Tetapkan ambang confidence per jenis aksi dan jalur eskalasi ke manusia.
- ☐ Kunci versi model (mis. `jev-1.13.0`), log field `model` di setiap respons.
- ☐ Simpan hasil validasi lama agar pergeseran (drift) saat ganti versi bisa diukur.
- ☐ Tinjau aspek data & kepatuhan (DPA, ZDR untuk enterprise) sebelum memproses data sensitif.

14. Data, privasi, dan kustomisasi

- Menurut dokumentasi, Jev **tidak dilatih** dengan request atau respons pelanggan. Data Processing Agreement tersedia, dan *zero data retention* ditawarkan untuk pelanggan enterprise.
- Jev **tidak di-fine-tune** per pelanggan; semua akun memakai bobot yang sama. Kustomisasi dilakukan lewat state, instructions, criteria, dan komposisi di kode.
- Untuk penggunaan di industri teregulasi (keuangan, kesehatan), mulai dari kasus berisiko rendah dan konfirmasi status sertifikasi kepatuhan langsung ke TypeSafe.

15. Glosarium

Istilah	Arti
System One model	Model yang mengembalikan keputusan bertipe dengan probabilitas, bukan teks
State	Konteks yang dinilai: teks, JSON, atau array teks
Choice / Score / Noul	Tiga tipe pertanyaan: pilih opsi / posisi pada skala / probabilitas ya
Confidence	Ringkasan 0–1 seberapa terpusat distribusi probabilitas
RLCD	Reinforcement Learning for Calibrated Decisions, metode pelatihan Jev
Speculative fan-out	Menanyakan banyak pertanyaan sekaligus, kode memakai yang relevan
Composite scoring	Menggabungkan beberapa jawaban dengan bobot di kode
Context rot	Turunnya akurasi akibat state berisi banyak hal tak relevan
Jaggedness	Daftar kelemahan model yang didokumentasikan TypeSafe

Sumber

- TypeSafe Docs: Models, Primitives, Confidence, Jev 1.13 jaggedness (docs.typesafe.ai)
- Deußer, Sparrenberg & Sifa, “Evaluating and Benchmarking the System One Model Jev”, arXiv 2609.37647
- “Comparative Evaluation of a System One Model and a General-Purpose LLM on the Korean Physical Therapist Licensing Examination”, medRxiv
- “Jev thinks ‘I don't know’, but doesn't say it: Introducing Sys1Cal-v1”, arXiv 2609.35342
- DataCamp, Sanity, Firecrawl, Requesty, Hyperstack: artikel penjelasan Jev (September–Oktober 2026)
- TypeSafe Docs: API Reference & SDK (Python, JavaScript); Vercel Docs, “TypeSafe API with AI Gateway”; Netlify Changelog, “TypeSafe Jev now available in AI Gateway”
- LangChain Blog, “Building a Harness with Jev”; LiteLLM Docs, “TypeSafe AI (Jev)”; Zuplo Docs, “Using Jev”
- Level Up Coding: “The Risks of Using JEV AI in Enterprise Software” dan “JEV AI: The Cheaper Model…”